

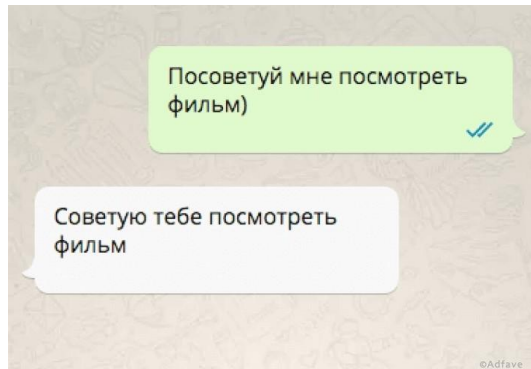
Recommendation systems

Егор Горюнов
yegor_goryunov@vk.com

МТУСИ

28.11.2023

Введение



Что рекомендуем?



Общая постановка задачи

$$u \in U$$



$$I_u \subset I$$

Интерстеллар

★★★★★



watched

2001 год: Космическая о...

★★★★★



watched

Nat Geo: Марс

★★★★★



bookmarked



Контакт

★★★★★



Сквозь горизонт

★★★★★



Последние дни на Марсе

★★★★★



Чужой: Завет

★★★★★



≧

≧

≧

$$i_1 \leq i_2 \vee i_2 \leq i_1 \forall i_1, i_2 \in I$$

Коллаборативная фильтрация




Постановка задачи

Дано:

- ▶ Пользователи (Users)
- ▶ Предметы (Items)
- ▶ Транзакции → Feedback (Explicit/Implicit)

Найти: $f_R : Users \times Items \mapsto Relevance\ score$ такую, что $\mathcal{L}(A, R) \rightarrow \min$.



Interaction Graph

	1	1	0	?
	0	0	1	?
	0	1	0	?
	0	0	1	?
	0	1	0	?

Interaction Matrix

Матричные разложения


Низкоранговая аппроксимация (low rank approximation):

$$A = R + E, \quad R = PQ^T$$

p_i - вектор скрытых признаков для i -го пользователя (user embedding)

q_j - вектор скрытых признаков для j -го предмета (item embedding)

$$r \approx p_i^T q_j = \sum_{k=1}^d p_{ik} q_{jk}$$



Сингулярное разложение

$$A = U \Sigma V^T$$


$$U \in \mathbb{R}^{M \times M}, \quad V \in \mathbb{R}^{N \times N}$$

$$U^T U = I_M, \quad V^T V = I_N$$

$\Sigma \in \mathbb{R}^{M \times N}$ - diagonal, with $[\Sigma]_{kk} = \sigma_k$:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(M,N)} \geq 0$$

$$\sigma_k(A) = \sqrt{\lambda_k(A^T A)} = \sqrt{\lambda_k(A A^T)}$$




Low-rank approximation task:

$$\|A - R\|_F^2 \rightarrow \min, \text{ s. t. } \text{rank}(R) = d$$

$$R = U_d \Sigma_d V_d^T$$

Прогнозирование с SVD



Заполним все пропуски нулями.


$$A_0 = U \Sigma V^T, \quad R = U_d \Sigma_d V_d^T$$

Прогнозирование оценки релевантности:

$$\begin{aligned} A_0 V_d V_d^T &= U \Sigma V^T [V_d \ 0] [V_d \ 0]^T = \\ &= U \Sigma [V_d \ 0]^T = U_d \Sigma_d V_d^T = R = A_0 V_d V_d^T \end{aligned}$$

Жизненный цикл RecSys модели

Gather initial data



Train a
model




Gather
feedback



Recommend



Эффект низкоранговой аппроксимации



Alternating Least Squares (ALS)

Постановка задачи:

$$\mathcal{L}(R, P, Q) = \|R - PQ^T\|^2 + \lambda\|P\|^2 + \mu\|Q\|^2 \rightarrow \min_{P, Q}$$

Найдём решение оптимизационной задачи:

$$\frac{1}{2} \frac{\partial \mathcal{L}}{\partial P} = (R - PQ^T)Q + \lambda P = 0 \Rightarrow P = RQ(Q^T Q + \lambda I)^{-1}$$

$$\frac{1}{2} \frac{\partial \mathcal{L}}{\partial Q} = P^T(R - PQ^T) + \mu Q = 0 \Rightarrow Q = R^T P(P^T P + \mu I)^{-1}$$

Задача сводится к поочерёдному расчёту линейной регрессии:

$$p_u = (Q^T Q + \lambda I)^{-1} Q^T r_u$$


$$q_i = R^T P(P^T P + \mu I)^{-1} P^T r_i$$

Холодный старт



Exploration vs Exploitation

1.	Побег из Шоушенка (1994) The Shawshank Redemption	9,191 (499 896)	7
2.	Зеленая миля (1999) The Green Mile	9,134 (467 865)	9
3.	Форрест Гамп (1994) Forrest Gump	9,013 (457 166)	9
4.	Список Шиндлера (1993) Schindler's List	8,885 (253 954)	☆
5.	1+1 (2011) Intouchables	8,833 (490 026)	9
6.	Леон (1994) Leon	8,775 (384 074)	9
7.	Мечело (2010) Inception	8,773 (523 300)	7
8.	Король Лев (1994) The Lion King	8,757 (326 049)	8
9.	Бойцовский клуб (1999) Fight Club	8,712 (446 692)	10
10.	Иван Васильевич меняет профессию (1973)	8,708 (345 823)	9



Модели на основе схожести


User-based:

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in U_i} \text{sim}(u, v)(r_{vi} - \bar{r}_v)}{\sum_{v \in U_i} \text{sim}(u, v)}$$

Item-based:

$$\hat{r}_{ui} = \bar{r}_i + \frac{\sum_{j \in I_u} \text{sim}(i, j)(r_{uj} - \bar{r}_j)}{\sum_{j \in I_u} \text{sim}(i, j)}$$

Content-based модели



Factorization Machines (FM)

$$\hat{r}(x) = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n v_i^T v_j x_i x_j, \quad w_0 \in \mathbb{R} \quad w \in \mathbb{R}^n \quad V \in \mathbb{R}^{n \times k}.$$

Feature vector \mathbf{x}																		Target y				
$\mathbf{x}^{(1)}$	1	0	0	...	1	0	0	0	...	0.3	0.3	0.3	0	...	13	0	0	0	0	...	5	$y^{(1)}$
$\mathbf{x}^{(2)}$	1	0	0	...	0	1	0	0	...	0.3	0.3	0.3	0	...	14	1	0	0	0	...	3	$y^{(2)}$
$\mathbf{x}^{(3)}$	1	0	0	...	0	0	1	0	...	0.3	0.3	0.3	0	...	16	0	1	0	0	...	1	$y^{(2)}$
$\mathbf{x}^{(4)}$	0	1	0	...	0	0	1	0	...	0	0	0.5	0.5	...	5	0	0	0	0	...	4	$y^{(3)}$
$\mathbf{x}^{(5)}$	0	1	0	...	0	0	0	1	...	0	0	0.5	0.5	...	8	0	0	1	0	...	5	$y^{(4)}$
$\mathbf{x}^{(6)}$	0	0	1	...	1	0	0	0	...	0.5	0	0.5	0	...	9	0	0	0	0	...	1	$y^{(5)}$
$\mathbf{x}^{(7)}$	0	0	1	...	0	0	1	0	...	0.5	0	0.5	0	...	12	1	0	0	0	...	5	$y^{(6)}$
	A	B	C	...	TI	NH	SW	ST	...	TI	NH	SW	ST	...	Time	TI	NH	SW	ST	...		
	User				Movie					Other Movies rated						Last Movie rated						

Резюме

Основные подходы в бизнесе:

1. Популярное + случайное
2. Коллаборативная фильтрация
3. Гибридный подход
4. Отбор + переранжирование

Литература

1. Рекомендательные системы: идеи, подходы, задачи - Хабр
2. People meet recommender systems. Factorization - Хабр
3. Abdolrahman Khoshroua, Eric J. Pauwelsa - "Regularisation for PCA- and SVD-type matrix factorisations" - arXiv:2106.12955 (2021)
4. Анатомия рекомендательных систем. Часть первая - Хабр
5. Анатомия рекомендательных систем. Часть вторая - Хабр
6. Рекомендательные системы: проблемы и методы решения. Часть 1 - Хабр



Обсудим?